

Санкт–Петербургский государственный университет

Стрельцова Александра Андреевна

Выпускная квалификационная работа

Глобальное сопоставление LiDAR облаков точек

Уровень образования: бакалавриат

Направление 01.03.02 «Прикладная математика и информатика»

Основная образовательная программа СВ.5005.2018 «Прикладная математика, фундаментальная информатика и программирование»

Профиль «Современное программирование»

Научный руководитель:

старший преподаватель,

Факультет математики и компьютерных наук,

к.ф.-м.н., Д. С. Шалымов

Рецензент:

руководитель группы,

ООО «Яндекс Беспилотные технологии»

М. В. Коробкин

Санкт-Петербург

2022 г.

Содержание

Введение	3
Постановка задачи	4
1. Обзор предметной области	5
1.1. Алгоритмы попарного сопоставления	5
1.1.1 Вероятностные алгоритмы	5
1.1.2 Алгоритмы, основанные на использовании соответствий	5
1.2. Дескрипторы, локальные системы координат и локальные оси	7
1.3. Выбор соответствий	8
1.4. Метрики RANSAC	8
2. Разработанный подход	10
2.1. Построение локальных систем координат	10
2.2. Выбор соответствий	11
2.3. Метрика RANSAC	14
3. Изучение модели, эксперименты	16
3.1. Постановка экспериментов	16
3.1.1 Датасеты	16
3.1.2 Метрики оценки качества результатов	18
3.2. Результаты экспериментов	19
3.3. Выводы	22
Заключение	23
Благодарность	23
Список литературы	24

Введение

Облака точек представляют собой наборы данных, состоящих из трёхмерных точек; как правило, эти точки предназначены для представления внешней поверхности объекта. Распространённым способом сбора данных облака точек является применение сканирующих приборов, использующих LiDAR (*Light Detection and Ranging* «обнаружение и определение дальности с помощью света») — технологию измерения расстояния путём излучения света и замера времени возвращения отражённого света на приёмник [32]. Кроме того, устройство многих сканирующих приборов позволяет при сканировании устанавливать их с учётом направления гравитации.

Облака точек заданы в локальной системе координат сканирующего прибора. *Сопоставление* (регистрация, выравнивание) облаков точек — процесс совмещения нескольких облаков точек в единую систему координат. Цель сопоставления — для каждого облака точек вычислить параметры преобразования,




Рис. 1: Сопоставление облаков точек.

матрицу поворота и вектор смещения, переводящие его в глобальную систему координат [Рис. 1]. Задача сопоставления облаков точек играет большую роль в важных приложениях компьютерного зрения, таких как восстановление трёхмерной модели объекта и трёхмерная локализация, то есть определение положения агента в трёхмерном пространстве.

Можно разделить алгоритмы сопоставления на два типа по количеству выравниваемых облаков: алгоритмы регистрации пары облаков точек и алгоритмы выравнивания нескольких (больше двух) облаков точек.

Большинство алгоритмов попарного сопоставления проходят в два этапа. Сначала осуществляется *глобальная* регистрация, получающая в качестве результата грубое приближение параметров искомого преобразова-

ния. Затем производится *локальная* регистрация — применяются алгоритмы оптимизации, направленные на уточнение полученной грубой оценки преобразования.

Алгоритмы попарного выравнивания облаков точек можно разделить на две категории: *вероятностные* алгоритмы и алгоритмы, основанные на получении *соответствий между точками* выравниваемых облаков, которые затем используются для вычисления параметров преобразования. В вероятностных алгоритмах результат сопоставления сильно зависит от результатов семплирования, поэтому они плохо справляются с выравниванием крупномасштабных облаков точек. Алгоритмы, строящие соответствия между точками, не всегда справляются с выравниванием из-за большого количества выбросов среди соответствий.

В данной дипломной работе исследуются алгоритмы глобального сопоставления пары LiDAR облаков точек и предлагается новый алгоритм, направленный на решение проблем существующих подходов и использование особенностей сканирующих приборов для повышения устойчивости выравнивания.

Постановка задачи

Цель данной работы – разработать алгоритм глобального сопоставления LiDAR облаков точек, основанный на построении соответствий между точками облаков и стабильно выравнивающий даже крупномасштабные облака точек. Для достижения сформулированной цели были поставлены следующие задачи:

- разработать метод фильтрации неверных соответствий;
- продумать и реализовать метод использования направления гравитации для повышения устойчивости сопоставления;
- протестировать алгоритм на доступных наборах крупномасштабных облаков точек.

1. Обзор предметной области

1.1. Алгоритмы попарного сопоставления

В случае попарного сопоставления выравниваемые облака точек могут быть обозначены как *исходное* и *целевое*. В таком случае результат сопоставления – параметры преобразования, переводящие исходное облако в систему координат целевого.

1.1.1 Вероятностные алгоритмы

В вероятностных алгоритмах применяется подход «один-ко-многим», что способствует рассмотрению большого количества возможных соответствий. В частности, вероятностные алгоритмы моделируют распределение облаков точек, которое затем оптимизируется либо с помощью корреляционного анализа [22], либо с помощью ЕМ-алгоритма [14].

1.1.2 Алгоритмы, основанные на использовании соответствий

Наиболее распространены алгоритмы, в которых строятся соответствия между точками облаков. Их можно разделить по типу получения соответствий на три группы.

Алгоритмы, использующие созданные вручную признаки, включают в себя три шага. Сначала осуществляется выделение геометрических признаков: линий пересечения пар плоскостей [18], точек пересечения троек плоскостей [19] или дескрипторов, задающих описания точек вместе с их окрестностями (обзор существующих видов дескрипторов представлен в секции 1.2). Затем между признаками исходного и целевого облаков формируются соответствия. На базе полученных соответствий вычисляются параметры преобразования. Геометрические признаки хорошо описывают структуры, встречающиеся в городской среде, однако их использование может привести к неудаче при выравнивании облаков, полученных в дикой природе, где представлено меньше структурных объектов.

В алгоритмах выравнивания, основанных на конгруэнтных четырехточечных множествах [1, 20], этап выделения геометрических признаков

опущен, и поиск соответствий осуществляется с использованием точек облака напрямую. Таким образом алгоритмы из данной группы проходят в два этапа: сначала выбираются четыре случайных точки исходного облака, лежащие в одной плоскости, затем путём перебора ищутся соответствующие им точки в целевом облаке, при этом используется факт инвариантности отношения в котором одна диагональ четырехугольника делит другую. По найденным соответствиям вычисляются параметры выравнивания. Перебор всех возможных решений гарантирует успешность данного метода, но может требовать слишком много времени.

В последние годы появляется всё больше алгоритмов выравнивания облаков точек, использующих методы глубокого машинного обучения для выделения признаков и построения соответствий между ними. Такие алгоритмы можно разделить на три типа, классифицируя их по способу представления данных. В алгоритмах первого типа облако точек делится с помощью регулярной трёхмерной сетки, после чего к нему применяются 3D-конволюционные нейронные сети [26]. Следующий тип алгоритмов вдохновлен алгоритмами сопоставления изображений. Сначала генерируются изображения, полученные из облака точек, наблюдаемого с разных ракурсов, затем к данным изображениям применяется 2D-свёрточная нейронная сеть и вычисляются признаки [28]. Наконец, алгоритмы третьего типа работают напрямую с облаками точек и, используя обученную нейронную сеть, по точкам вместе с их окрестностями, строят их дескрипторы и соответствия между ними [6]. Обученные признаки в отличие от созданных вручную лишены воздействия опыта их создателя и не ограничены в своей описательной способности. Методы глубокого обучения доказали свою эффективность в выравнивании мелкомасштабных облаков точек, однако, применение их к крупномасштабным облакам точек сопряжено с трудностями, вызванными высоким потреблением памяти.

1.2. Deskрипторы, локальные системы координат и локальные оси

Deskрипторы играют большую роль при сопоставлении точек одного облака с точками другого. Хороший deskриптор должен обладать высокой описательной способностью, гарантировать исчерпывающее и однозначное представление локальной геометрии. Чтобы обеспечить достоверное и эффективное сопоставление точек разных облаков, deskрипторы должны быть вычислительно эффективными, компактными и устойчивыми к шуму и изменениям в разрешениях облаков точек. На данный момент существуют многочисленные работы, предлагающие различные вариации deskрипторов. Существующие deskрипторы можно разделить на два типа в зависимости от того, используют они локальные системы координат (ЛСК) или нет. При вычислении deskрипторов без использования ЛСК распространён следующий подход: по точкам, лежащим в окрестности, формируется множество пар точек, по каждой паре точек и нормалям в них вычисляются некоторые численные характеристики взаимного расположения этих точек, которые затем используются для построения гистограмм, гистограммы конкатенируются и полученный массив чисел используется в качестве deskриптора; примерами такого подхода являются deskрипторы FPFH [16], NoPPF [27], PPTFH [23]. Также вместо локальной системы координат могут быть заданы только центр системы координат и одна ось отсчёта — чаще всего нормаль точки, окрестность которой используется для вычисления deskриптора. Для каждой точки в окрестности вычисляются значения некоторых функций, посчитанных относительно заданной оси, которые затем используются для построения гистограмм. Такой подход использован, например, при вычислении deskрипторов SI [11], LFSH [24], PPFH [4]. Deskрипторы, не требующие ЛСК, как правило являются легкими в вычислении, но обладают низкой описательной способностью, так как не учитывают в полной мере пространственное распределение точек в окрестности. В противоположность этому, deskрипторы с ЛСК учитывают расположение точек в пространстве. Корректно вычисленные ЛСК позволяют инвариантно относительно поворота и смещения разбить окрестность вокруг точки

на области, и строить гистограммы с учётом областей, в которые попадают точки, как это предлагается делать при вычислении дескрипторов USC [8], SHOT [21]. В работе, посвященной построению дескриптора RoPS [9], предлагается использовать статистики двумерных распределений, полученных проекцией точек окрестности на координатные плоскости ЛСК. Дескрипторы, использующие ЛСК, как правило, исчерпывающе описывают геометрию окрестности, однако, построение уникальной и устойчивой ЛСК затруднительно в случае плоскостей и сферических поверхностей и может быть сильно осложнено наличием шума.

1.3. Выбор соответствий

После того как для каждого облака получено множество дескрипторов, наступает этап построения соответствий. Прямой подход — для каждого дескриптора исходного облака найти наиболее близкий (похожий) дескриптор в целевом облаке, при этом метрики похожести могут быть разными в зависимости от дескриптора. Среди соответствий, полученных таким образом могут быть неверные. Для того чтобы понизить процент ложных соответствий применяют различные способы фильтрации соответствий. Один из возможных подходов — добавлять только те дескрипторы, для которых верно, что отношение расстояний до ближайшего и следующего ближайшего соседей не превышает заданный порог [13]. Также используется симметричная проверка (*left-right consistency check*), когда учитываются только те дескрипторы, которые сами являются ближайшими для своих ближайших соседей [5].

1.4. Метрики RANSAC

Несмотря на фильтрацию, большая доля соответствий, полученных путём сопоставления дескрипторов, — это выбросы, возникающие из-за шума, окклюзии, разницы в разрешениях облаков точек. Низкий процент верных соответствий может осложнять задачу вычисления матрицы поворота и вектора перемещения. Одним из наиболее часто используемых на практике методов построения устойчивой модели при наличии выбросов является

RANSAC (*RAN*dom *SA*mple *C*onsensus «консенсус случайных выборок») [7].

Как показано на рисунке 2, RANSAC в начале каждой итерации выбираются три случайных соответствия, по которым затем вычисляются параметры преобразования. Построение матрицы поворота и вектора смещения по трём парам точек — известная и подробно описанная задача [10]. Полученная гипотеза оценивается с помощью заранее установленной метрики. Итеративный процесс останавливается, когда достигнуто максимально допустимое количество итераций. Результатом RANSAC являются лучшие параметры преобразования.




Рис. 2: Схема работы алгоритма RANSAC.

Существующие метрики оценки параметров преобразования делятся на два типа: учитывающие только соответствия и рассматривающие все точки исходного облака после применения к нему оцениваемого преобразования. Классическим представителем метрик первого типа является количество соответствий, согласующихся с преобразованием (инлаеров). Также было предложено использовать функцию Хьюбера [16] и ряд непрерывных функций [25], по-разному оценивающих вклад инлаеров и выбросов. Метрики второго типа включают в себя расстояние между облаками точек [24] — среднее расстояний от каждой точки исходного облака до ближайшей точки целевого облака — и количество точек исходного облака, близких к целевому облаку [15].

2. Разработанный подход

2.1. Построение локальных систем координат

Одной из опциональных характеристик лазерного сканера является наличие инклинометра [31]. Инклинометр позволяет измерять угол наклона сканера относительно гравитационного поля Земли. Если сканер выровнен, ось Z полученных облаков точек не отличается от направления гравитации в пределах погрешности инклинометра.

В работе [2] направление гравитации, полученное из вертикальных осей зданий, используется при регистрации изображений для вычисления инвариантных к поворотам и смещениям направлений ориентации дескрипторов SIFT [12]. Мы предлагаем в случае, когда известно направление гравитации, использовать его вместе с посчитанными нормальными для построения ЛСК. P^s , P^t — выравниваемые облака точек. p_i^s , p_j^t — i -ая и j -ая точки облаков P^s и P^t соответственно. Тогда ЛСК:

$$u_i = n_i, \quad v_i = \frac{g \times u_i}{\|g \times u_i\|}, \quad w_i = \frac{u_i \times v_i}{\|u_i \times v_i\|},$$

где n_i — нормаль в точке p_i , g — направление гравитации [Рис. 3 (а)].

Описанный вариант построения ЛСК неустойчив, если угол между n_i и g слишком мал [Рис. 3 (б, в)]. Если $\arccos\langle n_i, g \rangle$ меньше заданного порога $\tau_{gravity} = 0.04$ рад, то для точки p_i мы используем алгоритм построения ЛСК, предложенный в [21].




Рис. 3: Локальные системы координат. (а) Система координат на базе нормали и направления гравитации. (б, в) Неустойчивость системы координат при маленьком угле между нормалью и направлением гравитации.

Использование направления гравитации позволяет строить уникальные ЛСК даже в случае плоскостей и сферических поверхностей. Увеличение количества корректно построенных ЛСК повышает вероятность построения верного соответствия [Рис. 4].




Рис. 4: Верные соответствия, полученные при использовании ЛСК (а) по умолчанию, (б) на базе направления гравитации. Количество верных соответствий увеличилось более чем в 20 раз.

2.2. Выбор соответствий

В этой главе описаны технические особенности предложенного нами алгоритма выбора соответствий. В основе нашего подхода лежит идея использования соседних точек для оценки соответствий. Подобная идея была предложена в алгоритме регистрации изображений, GMS [3].

Для каждой точки мы вычисляем дескриптор SHOT. H^s , H^t — посчитанные дескрипторы, h_i^s , h_j^t — дескрипторы точек p_i^s , p_j^t соответственно. $C_{initial}$ — исходные соответствия, полученные вычислением для каждого дескриптора H^s ближайшего соседа в H^t . Для подсчета расстояний между

дескрипторами используется евклидова метрика:

$$d_{L^2}(h^s, h^t) = \sqrt{\sum_{j=1}^k (h^s[j] - h^t[j])^2}$$

Будем считать, что соответствие $c_1 = (i_1, j_1)$ *голосует* за соответствие $c_2 = (i_2, j_2)$, и c_1 и c_2 *консистентны*, если $\rho(p_{i_1}^s, p_{i_2}^t)$ и $\rho(p_{j_1}^s, p_{j_2}^t)$ отличаются в пределах погрешности [Рис. 5 (а)].




Рис. 5: Визуализация консистентности соответствий. (а) Соответствия c_2 и c_3 консистентны, c_1 и c_2 — неконсистентны. (б) За верное соответствие голосуют соседние верные соответствия. (в) За неверное соответствие голосуют случайные неверные соответствия.


Среди соответствий могут быть неверные, наша цель — вычислить для каждого соответствия оценку его консистентности относительно других соответствий. Если окрестность i -ой точки является неуникальной, то в H^t может оказаться много дескрипторов, похожих на h_i^s , при этом соответствующие им точки могут быть распределены в облаке P^t случайным образом.

Предположение. За верные соответствия голосуют все верные соответствия, за неверные соответствия голосует только некоторая часть неверных соответствий [Рис. 5 (б, в)].


Суммарная оценка сложности подсчёта для каждого соответствия количества голосующих за него соответствий — $O(|P|^2)$. В нашем подходе для каждой точки p мы оцениваем её соответствие, используя только соответствия точек из окрестности p радиуса $r_{filtering}$, тогда асимптотика — $O(k|P|)$, где k — верхняя оценка на количество соседей в окрестности

установленного радиуса.

Обозначим множество точек, находящихся на расстоянии не больше чем r от p за $N_r(p)$. Пусть $c_1 = (i_1, j_1)$ — верное соответствие. Для точки $p_{i_2}^s \in N_r(p_{i_1}^s)$ верно, что если соответствующая ей пара $c_2 = (i_2, j_2)$ является верным соответствием, то $p_{j_2}^t \in N_r(p_{j_1}^t)$, если же неверным, то с большой вероятностью $p_{j_2}^t$ не попадёт в окрестность $p_{j_1}^t$ [Рис. 6].



(a)



(б)

Мы предлагаем следующую оценку качества соответствий:

Рис. 6: (a) c_2 — верное соответствие. (б) c_2 — неверное соответствие.

$$f^s(i_1, j_1) = \frac{|\{p_{j_2}^t \in N_r(p_{j_1}^t) \mid p_{i_2}^s \in N_r(p_{i_1}^s), (i_2, j_2) \in C_{initial}\}|}{|N_r(p_{i_1}^s)|}.$$

Аналогично мы оцениваем соответствие c_1 , анализируя соседей $p_{j_1}^t$:

$$f^t(i_1, j_1) = \frac{|\{p_{i_2}^s \in N_r(p_{i_1}^s) \mid p_{j_2}^t \in N_r(p_{j_1}^t), (i_2, j_2) \in C_{initial}\}|}{|N_r(p_{j_1}^t)|}.$$

Используя описанные оценки качества соответствий и установленный порог $\tau_{matches} = 0.8$ мы формируем множество соответствий:

$$C = \{(i, j) \mid f^s(i, j) < \tau_{matches}, f^t(i, j) < \tau_{matches}, (i, j) \in C_{initial}\},$$

которое будет использоваться на этапе вычисления параметров преобразования. Такой подход помогает бороться с выбросами, что особенно важно при сопоставлении облаков точек, полученных на улице и охватывающих большие участки регистрируемой местности [Рис. 7].




Рис. 7: Визуализация соответствий; верные соответствия выделены зелёным, неверные — красным. Для лучшего визуального восприятия оставлено только 2% случайных соответствий. (а) Сопоставляемые облака точек. (б) Соответствия, прошедшие симметричную проверку. (в) Соответствия, выбранные нашим способом. Процент верных соответствий увеличивается более чем в 2 раза.

2.3. Метрика RANSAC

В качестве метрики для оценки гипотез было решено использовать комбинацию двух метрик — количества инлаеров и количества точек исходного облака, близких к целевому. Обозначим за T_m гипотезу, полученную на m -ой итерации (T_m состоит из матрицы поворота $R_m \in SO(3)$ и вектора смещения $t_m \in \mathbb{R}^3$).

В таком случае метрика, учитывающая соответствия, может быть определена как:

$$s_{matches}(T_m) = \sum_{(i,j) \in C_{initial}} [e(i,j) < \tau_{err}],$$

где $e(i,j) = \|R_m p_i^s + t_m - p_j^t\|$ — ошибка соответствия и τ_{err} — порог, определяющий явля-




Рис. 8: Выравнивания, полученные с использованием (а) верной и (б) неверной гипотез.

ется ли соответствие инлаером. Метрика, учитывающая все точки исходного облака:

$$s_{closest}(T_m) = \sum_{i < |P^s|} [\rho(R_m p_i^s + t_m, P^t) < \tau_{err}],$$

где $\rho(p, P)$ — расстояние от точки p до ближайшей точки из P .

Несмотря на то что обе метрики дают хорошие результаты сопоставления и часто применяются на практике, они могут отдавать предпочтение неправильным гипотезам [Таб. 1].

Тест	Доля инлаеров среди соответствий		Доля точек в перекрытии		Произведение	
	Гипотеза 1	Гипотеза 2	Гипотеза 1	Гипотеза 2	Гипотеза 1	Гипотеза 2
16-14	0.079	0.013	0.094	0.294	0.007	0.004
23-24	0.085	0.070	0.336	0.246	0.028	0.017
90-88	0.030	0.038	0.274	0.049	0.008	0.002
96-94	0.066	0.107	0.195	0.025	0.013	0.003
97-95	0.007	0.115	0.299	0.087	0.002	0.010

Таблица 1: Значения метрик для гипотезы 1 (верной) и гипотезы 2 (неверной).

Это связано с тем, что $S_{matches}$ чувствительна к наличию повторяющихся и симметричных структур в облаке, а $S_{closest}$ имеет высокое значение, когда возникают перекрытия плоских участков с большой площадью поверхности [Рис. 8]. В связи с этим мы предлагаем использовать комбинацию двух метрик:

$$s(T_m) = s_{matches}(T_m) \cdot s_{closest}(T_m).$$

3. Изучение модели, эксперименты

3.1. Постановка экспериментов

В данной секции представлены результаты предложенного метода сопоставления облаков точек. Так как для нахождения матрицы преобразования используется RANSAC, результат работы алгоритма недетерминирован, поэтому на каждой паре облаков точек мы запустили алгоритм $r = 10$ раз, после чего вычислили процент успешных сопоставлений и усреднили ошибки выравнивания на успешных сопоставлениях. Перед запуском облака точек передискретизируются — точки облака разбиваются на воксели, после чего точки, попавшие в один воксел, заменяются на их центр масс. Параметры запуска и оценки результатов могут быть найдены в таблице 2. Реализация алгоритма осуществлялась на C++ с использованием открытой библиотеки для задач обработки облаков точек, PCL [17]. Код проекта доступен на GitHub.

Параметр	Значение
Сторона вокселя (м)	0.04
Радиус окрестности, используемой для вычисления нормали (м)	0.12
Радиус окрестности, используемой при оценке качества соответствий (м)	0.28
Радиус окрестности, используемой для построения дескриптора (м)	0.6
Порог для определения инлаеров, τ_{err} (м)	0.06
Порог для определения корректных соответствий, $\tau_{correct}$ (м)	0.06
Количество итераций RANSAC	1000000

Таблица 2: Параметры запуска алгоритма¹.

3.1.1 Датасеты

При проведении экспериментов был использован датасет «Кижич», состоящий из 97 облаков точек и полученный с использованием лазерного сканера FARO S70 [31] в музее-заповеднике «Кижич». В качестве истин-

¹Запуск на двух особо сложных тестах из датасета «Кижич» «16-14» и «23-22» осуществлялся со всеми параметрами, кроме количества итераций, уменьшенными вдвое. Это связано с тем, что сопоставление на этих облаках точек происходит исключительно за счёт мелких структурных элементов, которые хорошо заданы только при использовании высокого разрешения облаков точек.

ных значений параметров преобразований, переводящих облака в единую систему координат, использовали параметры, полученные с помощью полуавтоматической регистрации облаков точек с использованием программного оборудования, поставляемого вместе с лазерным сканером. Сканирование проводилось как внутри помещения, так и снаружи. Облака точек, полученные на улице, покрывают большие территории, при этом позиции сканера, как правило, находятся далеко друг от друга, в связи с чем пары облаков точек обладают маленьким перекрытием. Также сопоставление осложняется наличием симметричных и повторяющихся элементов. Для проведения экспериментов были отобраны пары облаков точек с перекрытием до 30%, вызывающие наибольшие трудности при выравнивании². Кроме того, были использованы три датасета, доступные в рамках проекта [30]. На рисунке 9 представлены облака точек, выровненные с использованием референсных значений параметров. В таблице 3 приведено краткое описание использованных датасетов.




Рис. 9: Наборы облаков точек, которые были использованы в экспериментах. Датасеты (а) «Кижи» (б) «Деревья» (в) «Арка» (г) «Офис». Для лучшего визуального восприятия оставлена только небольшая доля точек, кроме того удалён потолок в датасете (г).

²На всех парах из датасета «Кижи», имеющих перекрытие больше 1%, был запущен алгоритм глобальной регистрации, предложенный в библиотеке обработки облаков точек Open3D [29]; пары, которые не удалось сопоставить, были отобраны как трудные для сопоставления.

Датасет	# Скано	# Точек/Скан	# Пар	Тип местности	Применение
«Кижи»	97	20М	21	Интерьер и экстерьер	Документирование наследия
«Офис»	5	10М	8	Интерьер	Навигация внутри помещения
«Арка»	5	26М	8	Экстерьер	Документирование наследия
«Деревья»	6	20М	13	Лес	Лесоводство

Таблица 3: Описание датасетов.

3.1.2 Метрики оценки качества результатов

В качестве критерия оценки качества соответствий мы используем процент верных соответствий [24]. Мы считаем соответствие верным, если ошибка меньше заданного порога, $\tau_{correct}$. Ошибка соответствия задаётся как:

$$e_{GT}(i, j) = \|R_{GT}p_i^s + t_{GT} - p_j^t\|,$$

где R_{GT} и t_{GT} образуют референсные параметры преобразования T_{GT} . Как и в работе [20], мы используем ошибку поворота и ошибку смещения для оценки качества результатов сопоставления:

$$e_\theta(R) = \angle(R_{GT}R^T), \quad e_t(t) = \|t_{GT} - t\|.$$

Кроме того мы вычисляем среднеквадратическую ошибку смещений точек исходного облака, принадлежащих перекрытию $M_{overlap} = \{p^s \in P^s \mid \exists p^t \in P^t : \|R_{GT}p^s + t_{GT} - p^t\| < \tau_{correct}\}$:

$$RMSE_{overlap}(R, t) = \sqrt{\sum_{p^s \in M_{overlap}} \|[R_{GT}R^T]p^s + [t_{GT} - t] - p^s\|^2}.$$

Мы считаем, что сопоставление прошло успешно, если:

$$RMSE_{overlap}(R, t) \leq 1.5 \cdot \tau_{correct}.$$

Таким образом процент успешных сопоставлений (*success rate*):

$$SR = 100 \cdot \frac{1}{n} \cdot \sum_{i=1}^n [RMSE_{overlap}(R_i, t_i) \leq 1.5 \cdot \tau_{correct}],$$

где n — количество запусков теста, R_i и t_i — матрица поворота и вектор смещения, полученные на i -ом запуске.

3.2. Результаты экспериментов

Алгоритм построения соответствий был запущен на трудных парах облаков точек из датасета «Кизи». На рисунке 10 представлен график количества соответствий. Использование предложенной фильтрации соответствий вместо симметричной проверки снижает количество соответствий. Это особенно заметно во всех тестах, начиная с теста «90-88». Облака точек в этих тестах охватывают большие участки земли, поэтому многие дескрипторы не отличаются яркой выразительностью и среди соответствий встречается большое количество ложных.




Рис. 10: Количество соответствий, полученное при запуске алгоритма с использованием симметричной проверки, предложенной в данной работе фильтрации и фильтрации вместе с предложенным методом построения ЛСК.

При этом, как видно из графика на рисунке 11, количество верных соответствий не снижается. Также стоит отметить, что использование гравитации для построения дескрипторов существенно повышает количество верных соответствий.




Рис. 11: Количество верных соответствий, полученное при запуске алгоритма с использованием симметричной проверки, предложенной в данной работе фильтрации и фильтрации вместе с предложенным методом построения ЛСК.

Таким образом, процент верных соответствий повышается, что продемонстрировано графиком на рисунке 12.




Рис. 12: Процент верных соответствий, полученное при запуске алгоритма с использованием симметричной проверки, предложенной в данной работе фильтрации и фильтрации вместе с предложенным методом построения ЛСК.

Результаты работы алгоритма сопоставления представлены в таблицах 4 и 5. Добавление предложенных в данной работе модификаций повышает средний процент успешных сопоставлений на всех представленных датасетах (за исключением датасета «Офис», на котором процент успешных сопоставлений не изменяется и всегда максимален). Кроме того, стоит отметить, что различные модификации алгоритма могут в разной степени влиять на результаты сопоставления в зависимости от датасета. Так, количество успешных сопоставлений на датасете «Арка», снятом на улице и захватывающем большие площади поверхности, заметно увеличивается при использовании новой метрики оценки параметров преобразования, в то время как на датасете «Деревья», покрывающем большое количество похожих объектов, большое влияние имеет использование предложенного алгоритма фильтрации соответствий.

Фильтрация	Метрика	Гравитация	«Кижи»			
			MSR (%)	MTE (мм)	MAE (°)	MRMSE (мм)
			57	37 ± 14	0.16 ± 0.05	36 ± 7
	✓		70	38 ± 12	0.13 ± 0.05	35 ± 6
	✓	✓	82	38 ± 13	0.13 ± 0.04	34 ± 6
	✓	✓	93	33 ± 11	0.16 ± 0.06	31 ± 7

Таблица 4: Оценки качества сопоставления – средний процент успешных сопоставлений (MSR), средняя ошибка смещения (MTE), средняя угловая ошибка (MAE) и средняя среднеквадратическая ошибка смещений точек (MRMSE) – на тестах датасета «Кижи».

Фильтрация	Метрика	«Офис»			
		MSR (%)	MTE (мм)	MAE (°)	MRMSE (мм)
		100	17 ± 5	0.19 ± 0.08	22 ± 5
	✓	100	16 ± 6	0.20 ± 0.09	23 ± 7
	✓	100	17 ± 6	0.18 ± 0.07	22 ± 6
Фильтрация	Метрика	«Арка»			
		MSR (%)	MTE (мм)	MAE (°)	MRMSE (мм)
		66	22 ± 9	0.07 ± 0.03	27 ± 7
	✓	65	18 ± 8	0.07 ± 0.03	23 ± 8
	✓	95	20 ± 7	0.06 ± 0.03	27 ± 7
Фильтрация	Метрика	«Деревья»			
		MSR (%)	MTE (мм)	MAE (°)	MRMSE (мм)
		57	20 ± 6	0.12 ± 0.04	33 ± 6
	✓	97	16 ± 6	0.11 ± 0.05	28 ± 9
	✓	99	16 ± 6	0.09 ± 0.04	26 ± 7

Таблица 5: Оценки качества сопоставления – средний процент успешных сопоставлений (MSR), средняя ошибка смещения (MTE), средняя угловая ошибка (MAE) и средняя среднеквадратическая ошибка смещений точек (MRMSE) – на тестах датасетов «Офис», «Арка» и «Деревья».

3.3. Выводы

После анализа результатов проведённых экспериментов может быть сделано несколько выводов. Во-первых, описанная в данной работе фильтрация соответствий значительно снижает количество неверных соответствий, повышая тем самым вероятность генерации случайной выборки из трёх верных соответствий, а значит — нахождения корректных параметров преобразования. Во-вторых, предложенная метрика оценки параметров преобразования повышает вероятность выбора правильного выравнивания на облаках точек, снятых снаружи и покрывающих большие площади поверхности. В-третьих, использование направления гравитации позволяет строить однозначные ЛСК, что в свою очередь повышает количество верных соответствий.

Предложенный алгоритм глобального сопоставления LiDAR облаков точек успешно выравнивает даже трудные пары облаков точек и может быть использован для решения задачи регистрации облаков точек на практике.

Заключение

В рамках данной работы были достигнуты следующие результаты:

- был разработан метод фильтрации неверных соответствий, заметно повышающий процент верных соответствий и увеличивающий вероятность успешного сопоставления;
- была предложена новая метрика, комбинирующая в себе преимущества существующих метрик;
- был разработан метод построения соответствий, использующий направление гравитации;
- полученный алгоритм был протестирован на нескольких доступных датасетах и при применении каждой из предложенных модификаций продемонстрировал заметное улучшение результатов.

Дальнейшая работа может быть направлена на:

- улучшение производительности предложенного метода;
- внедрение данного метода в алгоритм сопоставления нескольких (больше двух) облаков точек.

Благодарность

Автор благодарит Николая Полярного за регулярные наставления и помощь в проведении данного исследования.

Список литературы

- [1] D. AIGER, N. J. MITRA, AND D. COHEN-OR, *4-points congruent sets for robust pairwise surface registration*, ACM SIGGRAPH 2008 papers, (2008).
- [2] G. BAATZ, K. KÖSER, D. M. CHEN, R. GRZESZCZUK, AND M. POLLEFEYS, *Handling urban location recognition as a 2d homothetic problem*, in ECCV, 2010.
- [3] J. BIAN, W.-Y. LIN, Y. MATSUSHITA, S.-K. YEUNG, T. D. NGUYEN, AND M.-M. CHENG, *Gms: Grid-based motion statistics for fast, ultra-robust feature correspondence*, 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), (2017), pp. 2828–2837.
- [4] A. G. BUCH AND D. KRAFT, *Local point pair feature histogram for accurate 3d matching*, in BMVC, 2018.
- [5] C. CHANG, S. CHATTERJEE, AND P. R. KUBE, *On an analysis of static occlusion in stereo vision*, Proceedings. 1991 IEEE Computer Society Conference on Computer Vision and Pattern Recognition, (1991), pp. 722–723.
- [6] H. DENG, T. BIRDAL, AND S. ILIC, *Ppfnet: Global context aware local features for robust 3d point matching*, 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition, (2018), pp. 195–205.
- [7] M. A. FISCHLER AND R. C. BOLLES, *Random sample consensus: a paradigm for model fitting with applications to image analysis and automated cartography*, Commun. ACM, 24 (1981), pp. 381–395.
- [8] A. FROME, D. F. HUBER, R. K. KOLLURI, T. BÜLOW, AND J. MALIK, *Recognizing objects in range data using regional point descriptors*, in ECCV, 2004.

- [9] Y. GUO, F. SOHEL, BENNAMOUN, M. LU, AND J. WAN, *Rotational projection statistics for 3d local surface description and object recognition*, International Journal of Computer Vision, 105 (2013), pp. 63–86.
- [10] A. HARLLEY AND A. ZISSERMAN, in Multiple view geometry in computer vision (2. ed.), 2003.
- [11] A. E. JOHNSON AND M. HEBERT, *Surface matching for object recognition in complex three-dimensional scenes*, Image Vis. Comput., 16 (1998), pp. 635–651.
- [12] D. G. LOWE, *Object recognition from local scale-invariant features*, Proceedings of the Seventh IEEE International Conference on Computer Vision, 2 (1999), pp. 1150–1157 vol.2.
- [13] G. LOWE DAVID, *Distinctive image features from scale-invariant keypoints*, International Journal of Computer Vision, (2004).
- [14] A. MYRONENKO, X. B. SONG, AND M. Á. CARREIRA-PERPIÑÁN, *Non-rigid point set registration: Coherent point drift*, in NIPS, 2006.
- [15] S. QUAN, J. MA, F. HU, B. FANG, AND T. MA, *Local voxelized structure for 3d binary feature representation and robust registration of point clouds from low-cost sensors*, Inf. Sci., 444 (2018), pp. 153–171.
- [16] R. B. RUSU, N. BLODOW, AND M. BEETZ, *Fast point feature histograms (fpfh) for 3d registration*, 2009 IEEE International Conference on Robotics and Automation, (2009), pp. 3212–3217.
- [17] R. B. RUSU AND S. B. COUSINS, *3d is here: Point cloud library (pcl)*, 2011 IEEE International Conference on Robotics and Automation, (2011), pp. 1–4.
- [18] I. STAMOS AND M. LEORDEANU, *Automated feature-based range registration of urban scenes of large scale*, 2003 IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 2003. Proceedings., 2 (2003), pp. II–Ii.

- [19] P. W. THEILER AND K. SCHINDLER, *Automatic registration of terrestrial laser scanner point clouds using natural planar surfaces*, ISPRS Annals of the Photogrammetry, Remote Sensing and Spatial Information Sciences, (2012), pp. 173–178.
- [20] P. W. THEILER, J. D. WEGNER, AND K. SCHINDLER, *Keypoint-based 4-points congruent sets – automated marker-less registration of laser scans*, Isprs Journal of Photogrammetry and Remote Sensing, 96 (2014), pp. 149–163.
- [21] F. TOMBARI, S. SALTI, AND L. DI STEFANO, *Unique signatures of histograms for local surface description*, in ECCV, 2010.
- [22] Y. TSIN AND T. KANADE, *A correlation-based approach to robust point set registration*, in ECCV, 2004.
- [23] L. WU, K. ZHONG, Z. LI, M. ZHOU, H. HU, C. WANG, AND Y. SHI, *Pptfh: Robust local descriptor based on point-pair transformation features for 3d surface matching*, Sensors (Basel, Switzerland), 21 (2021).
- [24] J. YANG, Z. CAO, AND Q. ZHANG, *A fast and robust local descriptor for 3d point cloud registration*, Inf. Sci., 346-347 (2016), pp. 163–179.
- [25] J. YANG, Z. HUANG, S. QUAN, Q. ZHANG, Y. ZHANG, AND Z. CAO, *On efficient and robust metrics for ransac hypotheses and 3d rigid registration*, ArXiv, abs/2011.04862 (2020).
- [26] Z. ZHANG, L. SUN, R. ZHONG, D. CHEN, Z. XU, C. WANG, C.-Z. QIN, H. SUN, AND R. LI, *3-d deep feature construction for mobile laser scanning point cloud registration*, IEEE Geoscience and Remote Sensing Letters, 16 (2019), pp. 1904–1908.
- [27] H. ZHAO, M. TANG, AND H. DING, *Hoppf: A novel local surface descriptor for 3d object recognition*, Pattern Recognit., 103 (2020), p. 107272.

- [28] L. ZHOU, S. ZHU, Z. LUO, T. SHEN, R. ZHANG, M. ZHEN, T. FANG, AND L. QUAN, *Learning and matching multi-view descriptors for registration of point clouds*, ArXiv, abs/1807.05653 (2018).
- [29] Q.-Y. ZHOU, J. PARK, AND V. KOLTUN, *Open3d: A modern library for 3d data processing*, ArXiv, abs/1801.09847 (2018).
- [30] *Automatic registration of partially overlapping terrestrial laser scanner point clouds.* https://prs.igp.ethz.ch/research/completed_projects/automatic_registration_of_point_clouds.html. [Online; accessed 24-May-2022].
- [31] *Faro laser scanner user manual.* https://echosurveying.com/docs/Faro_Focus_M70_S70_S150_S350_User_Manual.pdf", 2018.
- [32] *Lidar — Wikipedia, the free encyclopedia.* <https://en.wikipedia.org/w/index.php?title=Lidar&oldid=1087322947>. [Online; accessed 24-May-2022].